



DataScientist Society

# モデルの精度評価

～AUC, Log Loss, RMSE, MAE, NDCG, MAP@ $n$ ～

# モデルの精度評価

## ➤ モデルの精度とは?

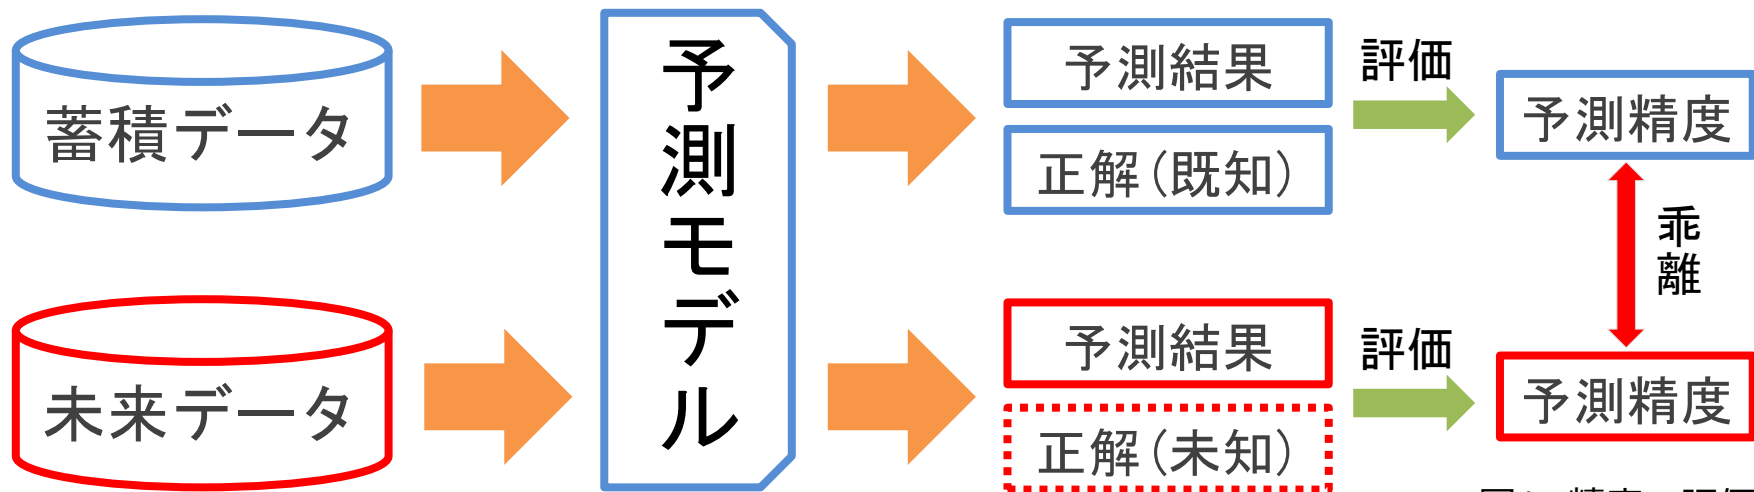


図1: 精度の評価

過去の蓄積データから予測モデルを構築し、蓄積データに対するモデルの精度は、評価指標(詳しくは後述)により測れる。しかし、未知の未来データに対しては、結果が出てからでないと確かめられない。また、未来の結果が出たとしても、蓄積データでの予測精度と未来データでの予測精度では、しばしば乖離が発生する。したがって、

モデルの精度 = 既知データでの予測精度 × 乖離幅  
で考える必要がある。

# モデルの精度評価

## ➤ 精度評価方法

モデルが予測するものは、個数、分類、順序などがあり、それらに対して、いくつかの評価指標が知られている。モデルの精度評価を正しく理解するには、評価指標の正しい理解が必要不可欠である。

表1: 評価指標一覧

評価指標	予測対象	値域	見方
AUC	2群分類. 例:医療診断, 契約.	0 ~ 1	値が大きい方が良い
Log Loss	3群以上の分類. 例:運転行動.	0 ~ $\infty$	値が小さい方が良い
RMSE	個数. 例:売り上げ個数, 降水量.	0 ~ $\infty$	値が小さい方が良い
MAE	個数. 例:売り上げ個数, 降水量.	0 ~ $\infty$	値が小さい方が良い
NDCG	順序. 例:検索結果, 商品推薦.	0 ~ 1	値が大きい方が良い
MAP@n	(2群分類) <sup>n</sup> ×順序. 例:購入商品.	$0 \sim \sum_{i=1}^n 1/k$	値が大きい方が良い

# モデルの精度評価

## ➤ 精度評価方法

モデルが予測するものは、個数、分類、順序などがあり、それらに対して、いくつかの評価指標が知られている。モデルの精度評価を正しく理解するには、評価指標の正しい理解が必要不可欠である。

表1: 評価指標一覧

評価指標		値域	見方
AUC	2群分類	0 ~ 1	値が大きい方が良い
Log Loss	3群以上の分類。例: 運転行動。	0 ~ $\infty$	値が小さい方が良い
RMSE	個数。例: 売り上げ個数, 降水量。	0 ~ $\infty$	値が小さい方が良い
MAE	個数。例: 売り上げ個数, 降水量。	0 ~ $\infty$	値が小さい方が良い
NDCG	順序。例: 検索	0 ~ 1	値が大きい方が良い
MAP@n	(2群分類) <sup>n</sup> × 順序。例: 購入商品。	0 ~ $\sum_{i=1}^n 1/i$	値が大きい方が良い

今回の講座で  
使用する評価指標

ここを見るだけ  
では駄目！

# モデルの精度評価(RMSE)

## ➤ RMSE (Root Mean Squared Error)

RMSEとは,  $N$  = 予測対象数,  $y_i$  = 実現値,  $\hat{y}_i$  = 予測値として,

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

で定義される. 予測対象全てを誤差無しに当てることができれば, 値は0となる. 1ヶ所大きく外すと, 値はより大きくなる.




図2: Model

左図の赤い縦線の長さが,  
Modelの予測値と実現値の  
差を表しており,  
 $y_i - \hat{y}_i$   
と対応している.

# モデルの精度評価(分類)

## ➤ 分類の精度とは?

いま, 犬と猫の混合データがあり, データから犬か猫かを分類したい.  
仮に, 体重で識別するモデルと, エサ代で識別するモデルを考える.




図3: 体重モデル




図4: エサ代モデル

図3, 4の場合, A, Bをそれぞれの閾値として分類する. なるべく2群の山が, 重ならないようになるモデルの方が識別が出来ている. そこで, 「重なり具合」から精度を評価することを考える.

# モデルの精度評価(正解率と誤分類率)

## ➤ 正解率と誤分類率

「重なり具合」の指標の1つとして, 正解率と誤分類率が考えられる.

正解率 = (予測対象の内, 正しく分類した割合)

誤分類率 = (予測対象の内, 誤って分類した割合)

表2: 予測データ1

番号	真の分類	体重[kg]	予測
1	犬	32.3	犬
2	犬	25.4	
3	犬	15.2	
4	猫	10.1	
5	犬	8.7	10kg
6	猫	7.5	猫
7	犬	6.9	
8	猫	4.8	
9	猫	4.3	
10	猫	3.2	

表2は10匹(犬5匹, 猫5匹)の予測対象データを体重の重い順に並べたものである. このとき, 10kgを閾値として**体重モデル(Model1)**を考えると,

正解率 =  $(3+4)/(5+5) = 0.7$

誤分類率 =  $(1+2)/(5+5) = 0.3$

と計算できる.

しかし, この正解率、誤分類率ではモデルの精度を上手く説明できない.

# モデルの精度評価(正解率と誤分類率)

## ➤ 極端なデータの誤分類率

極端に猫の件数が多い場合を考える. いま, 表2の猫の件数が, そのまま100倍の件数になるデータを表3とする. このとき, 犬5匹, 猫500匹に対して, Model1と, 体重に関係なく**全てを猫と分類するモデル(Model2)**を考える.

表3: 予測データ2

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4~103	猫	10.1
104	犬	8.7
105~204	猫	7.5
205	犬	6.9
206~305	猫	4.8
306~405	猫	4.3
406~505	猫	3.2

Model1  
予測

犬

10kg

猫

Model2  
予測

猫

猫

• Model1の誤分類率:  
 $(100+2)/(500+5) \div 0.20$

• Model2の誤分類率:  
 $(0+5)/(500+5) \div 0.01$

以上の結果より, 誤分類率を指標とすると, Model2の方が20倍精度の良いことになる.

→**この場合は, 誤分類率は精度評価には使えない.**



# モデルの精度評価(混同行列)

## ➤ 混同行列(Confusion Matrix)

異なる数の2群を予測するモデルに対しての指標を考えるために、**混同行列**を定義する。混同行列は下記の4種類の値を行列にしたものである。

True Positive(TP) : 犬を**犬**と予測した数

False Negative(FN) : 犬を**猫**と予測した数

False Positive(FP) : 猫を**犬**と予測した数

True Negative(TN) : 猫を**猫**と予測した数

表4: 予測データ1(再掲)

番号	真の分類	体重[kg]	予測
1	犬	32.3	犬
2	犬	25.4	
3	犬	15.2	
4	猫	10.1	
5	犬	8.7	猫
6	猫	7.5	
7	犬	6.9	
8	猫	4.8	
9	猫	4.3	
10	猫	3.2	

表5: 予測データ1の混同行列

		予測の分類		合計
		犬	猫	
真の分類	犬	True Positive (TP) 3	False Negative (FN) 2	Positive (P) 5
	猫	False Positive (FP) 1	True Negative (TN) 4	Negative (N) 5

※ここでは、犬を予測したい対象(Positive)とする。

# モデルの精度評価(適合率・再現率)

## ➤ 適合率と再現率

### 適合率

予測の分類が犬のうち、真の分類も犬である割合： $TP/(TP+FP)=0.75$

犬の予測精度を評価

### 再現率

真の分類が犬のうち、予測の分類も犬である割合： $TP/(TP+FN)=0.6$

犬の取りこぼしを評価

表4: 予測データ1(再掲)

番号	真の分類	体重[kg]	予測
1	犬	32.3	犬
2	犬	25.4	
3	犬	15.2	
4	猫	10.1	
5	犬	8.7	猫
6	猫	7.5	
7	犬	6.9	
8	猫	4.8	
9	猫	4.3	
10	猫	3.2	

表5: 予測データ1の混同行列

		予測の分類		合計
		犬	猫	
真の分類	犬	True Positive (TP) 3	False Negative (FN) 2	Positive (P) 5
	猫	False Positive (FP) 1	True Negative (TN) 4	Negative (N) 5

※ここでは、犬を予測したい対象(Positive)とする。

# モデルの精度評価(適合率・再現率)

## ➤ 極端なデータの適合率と再現率

先ほどと同様に、極端に猫の件数が多い場合を考える。犬5匹, 猫500匹に対して, Model1と, **全てを猫と分類するモデル(Model2)**を考える。

表: 予測データ2(再掲) Model1 Model2

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4~103	猫	10.1
104	犬	8.7
105~204	猫	7.5
205	犬	6.9
206~305	猫	4.8
306~405	猫	4.3
406~505	猫	3.2



Model1

		予測の分類		
		犬	猫	合計
真の分類	犬	True Positive 3	False Negative 2	Positive 5
	猫	False Positive 100	True Negative 400	Negative 500

Model2

		予測の分類		
		犬	猫	合計
真の分類	犬	True Positive 0	False Negative 5	Positive 5
	猫	False Positive 0	True Negative 500	Negative 500

# モデルの精度評価(適合率・再現率)

## ➤ 極端なデータの適合率と再現率

先ほどと同様に, 極端に猫の件数が多い場合を考える. 犬5匹, 猫500匹に対して, Model1と, **全てを猫と分類するモデル(Model2)**を考える.

	適合率	再現率
Model1	$3/103 \div 0.02$	$3/5 = 0.6$
Model2	算出不能( $0/0$ )	$0/5 = 0$

以上の結果より, 適合率は比較できず, 再現率はModel1が高くなる.  
適合率, 再現率どちらを重視するかは, 問題により異なる.

Model1

		予測の分類		
		犬	猫	合計
真の分類	犬	True Positive 3	False Negative 2	Positive 5
	猫	False Positive 100	True Negative 400	Negative 500

Model2

		予測の分類		
		犬	猫	合計
真の分類	犬	True Positive 0	False Negative 5	Positive 5
	猫	False Positive 0	True Negative 500	Negative 500

# モデルの精度評価(適合率・再現率)

## ➤ 適合率と再現率の例

適合率と再現率はどちらを使えばよいかは、分析目的に依存する。

例) クレジットカードのデフォルト予測

あなたがクレジットカードのデフォルトを予測するとき、どのような予測をするべきか？

### 再現率を重視する場合

- ・デフォルトする人の取りこぼしを評価。
- ・デフォルトする人をできるだけ検知したいときに使用。

### 適合率を重視する場合

- ・デフォルトする人の予測精度を評価。
- ・効率的にデフォルトする人を検知したいときに使用。

重視する指標を決め、条件付き指標(再現率が0.8を超える中でできるだけ適合率を上げるなど)を使用することもある。

# モデルの精度評価(AUC)①

➤ 偽陽性率と真陽性率(引用: はじめてのパターン認識, 第3章)

適合率や再現率は**閾値を設定する必要があり**、また**TNが考慮されていない**。それらを考慮した指標であるAUCを紹介する。まずは下記のように**偽陽性率と真陽性率**を定義する。

真陽性率 = **犬の中**で犬と正しく分類した割合、

偽陽性率 = **猫の中**で犬と誤分類した割合

表5: 予測データ1の混同行列

表4: 予測データ1(再掲)

番号	真の分類	体重[kg]	予測
1	犬	32.3	犬
2	犬	25.4	
3	犬	15.2	
4	猫	10.1	
5	犬	8.7	猫
6	猫	7.5	
7	犬	6.9	
8	猫	4.8	
9	猫	4.3	
10	猫	3.2	

		予測の分類		合計
		犬	猫	
真の分類	犬	True Positive (TP) 3	False Negative (FN) 2	Positive (P) 5
	猫	False Positive (FP) 1	True Negative (TN) 4	Negative (N) 5

・ 真陽性率:  $TP/P = 3/5 = 0.6$

・ 偽陽性率:  $FP/N = 1/5 = 0.2$

# モデルの精度評価(AUC)②

偽陽性率(偽)と真陽性率(真)は, 両方とも片方の群のみから算出されるので, **2群の数が異なる場合でも有効な指標である.**

閾値を $+\infty$ から下げていき, 偽陽性率が増えずに真陽性率が増えれば2群同士の「重なり合い」が少ない指標となる.




図5: 「重なり具合」偽陽性率と真陽性率

# モデルの精度評価(AUC)②

偽陽性率(偽)と真陽性率(真)は, 両方とも片方の群のみから算出されるので, **2群の数が異なる場合でも有効な指標である.**

閾値を $+\infty$ から下げていき, 偽陽性率が増えずに真陽性率が増えれば2群同士の「重なり合い」が少ない指標となる.




図5: 「重なり具合」偽陽性率と真陽性率



# モデルの精度評価(AUC)②

偽陽性率(偽)と真陽性率(真)は, 両方とも片方の群のみから算出されるので, **2群の数が異なる場合でも有効な指標である.**

閾値を $+\infty$ から下げていき, 偽陽性率が増えずに真陽性率が増えれば2群同士の「重なり合い」が少ない指標となる.




図5: 「重なり具合」偽陽性率と真陽性率

# モデルの精度評価(AUC)②

偽陽性率(偽)と真陽性率(真)は、両方とも片方の群のみから算出されるので、**2群の数が異なる場合でも有効な指標である。**

閾値を $+\infty$ から下げていき、偽陽性率が増えずに真陽性率が増えれば2群同士の「重なり合い」が少ない指標となる。




図5: 「重なり具合」偽陽性率と真陽性率

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分でつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分でつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

$$\text{偽陽性率} = 0/5 = 0$$

$$\text{真陽性率} = 0/5 = 0$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分をつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬  
↑

$$\text{偽陽性率} = 0/5 = 0$$

$$\text{真陽性率} = 1/5 = 0.2$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分をつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬  
↑

偽陽性率

$$= 0/5 = 0$$

真陽性率

$$= 2/5 = 0.4$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分をつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

偽陽性率

$$= 0/5 = 0$$

真陽性率

$$= 3/5 = 0.6$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分をつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

$$\text{偽陽性率} = \frac{1}{5} = 0.2$$

$$\text{真陽性率} = \frac{3}{5} = 0.6$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0



# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分でつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

$$\text{偽陽性率} = \frac{1}{5} = 0.2$$

$$\text{真陽性率} = \frac{4}{5} = 0.8$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分をつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

$$\text{偽陽性率} = \frac{2}{5} = 0.4$$

$$\text{真陽性率} = \frac{4}{5} = 0.8$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分でつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

偽陽性率

$$= \frac{2}{5} = 0.4$$

真陽性率

$$= \frac{5}{5} = 1.0$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分でつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

$$\text{偽陽性率} = \frac{3}{5} = 0.6$$

$$\text{真陽性率} = \frac{5}{5} = 1.0$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分をつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

$$\text{偽陽性率} = \frac{4}{5} = 0.8$$

$$\text{真陽性率} = \frac{5}{5} = 1.0$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)③

## ➤ ROC曲線の作成

先程の偽陽性率と真陽性率の変化をグラフで表したものを, ROC曲線(Receiver Operating Characteristic curve)と呼び, 横軸に偽陽性率, 縦軸に真陽性率をとり, 閾値を $+\infty$ から下げたときの変化を線分でつないだ曲線である.

表6: 予測データ1(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4	猫	10.1
5	犬	8.7
6	猫	7.5
7	犬	6.9
8	猫	4.8
9	猫	4.3
10	猫	3.2

犬

$$\text{偽陽性率} = \frac{5}{5} = 1.0$$

$$\text{真陽性率} = \frac{5}{5} = 1.0$$



表7: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4	猫	10.1	0.2	0.6
5	犬	8.7	0.2	0.8
6	猫	7.5	0.4	0.8
7	犬	6.9	0.4	1.0
8	猫	4.8	0.6	1.0
9	猫	4.3	0.8	1.0
10	猫	3.2	1.0	1.0

# モデルの精度評価(AUC)④

表7をプロットすると図6の様に階段の形の曲線が出来る. また, 2群が重なることなく完全に分類された場合は, 図7の様になり, ランダム分類された場合は, 図8の様になる.

## ➤ AUCの定義

ROC曲線下の面積をAUC値とする.

したがって, 図6のAUCは,

$$AUC = 0.2 \times 0.6 + 0.2 \times 0.8 + 0.6 \times 1.0 = 0.88$$

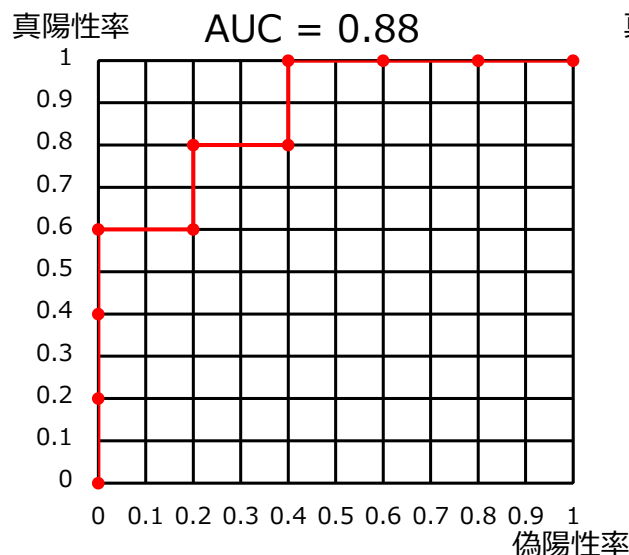


図6: ROC曲線(予測データ1)




図7: ROC曲線(完全分類)

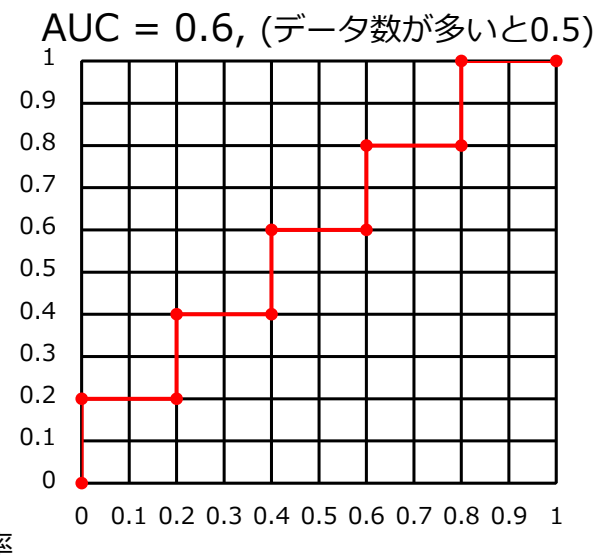


図8: ROC曲線(ランダム分類)

# モデルの精度評価(AUC)⑤

## ➤ AUCの比較1

ここで、先ほど誤分類率では出来なかった、モデルの精度評価に戻る。  
極端に猫に偏った予測データ2のROC曲線は、予測データ1と一致する。  
したがって、AUCの値も**一致する**ので、群の偏りによらず安定な精度評価が出来ている。

表8: 予測データ2(再掲)

番号	真の分類	体重[kg]
1	犬	32.3
2	犬	25.4
3	犬	15.2
4~103	猫	10.1
104	犬	8.7
105~204	猫	7.5
205	犬	6.9
206~305	猫	4.8
306~405	猫	4.3
406~505	猫	3.2

計算例:  
偽陽性率  
=  $100/500$   
= **0.2**

真陽性率  
=  $3/5$   
= **0.6**



表9: ROC曲線準備

番号	真の分類	体重[kg]	偽陽性率	真陽性率
1	犬	32.3	0.0	0.2
2	犬	25.4	0.0	0.4
3	犬	15.2	0.0	0.6
4~103	猫	10.1	<b>0.2</b>	<b>0.6</b>
104	犬	8.7	0.2	0.8
105~204	猫	7.5	0.4	0.8
205	犬	6.9	0.4	1.0
206~305	猫	4.8	0.6	1.0
306~405	猫	4.3	0.8	1.0
406~505	猫	3.2	1.0	1.0



# モデルの精度評価(AUC)⑥

## ➤ AUCの比較2


次に, 全てを猫と分類するモデルの精度評価を行う. いま, 全てを猫と分類するモデルのAUCは, 予測データ1も予測データ2も0.5である. なぜならば, 表10の様に猫フラグを全てに立てているのと同じことで, 全てのデータが同時に閾値を超えるので,  $(0,0) \rightarrow (1,1)$ となる.

表10: 猫フラグ

番号	真の分類	猫フラグ
1	犬	1
2	犬	1
3	犬	1
4~103	猫	1
104	犬	1
105~204	猫	1
205	犬	1
206~305	猫	1
306~405	猫	1
406~505	猫	1

表11: ROC曲線準備

閾値	偽陽性率	真陽性率
$+\infty \sim 1$	0.0	0.0
1未満	1.0	1.0



AUC = 0.5

図9: ROC曲線(全猫)

# モデルの精度評価(AUC)⑦

## ➤ AUCの比較3

誤分類率とAUCの値を, 予測データ1と予測データ2ごとにまとめる.

表12: 精度評価比較(予測データ1)

予測データ1		モデル	
		体重モデル	全て猫と分類する モデル
指 標	誤分類率	0.3	0.5
	AUC	0.88	0.5

表13: 精度評価比較(予測データ2)

予測データ2		モデル	
		体重モデル	全て猫と分類する モデル
指 標	誤分類率	0.2	0.01
	AUC	0.88	0.5

表12, 表13を比べると, AUCは安定して精度評価を行っていることが分かる. したがって, 2群分類モデルの精度評価はAUCが有用である.

データの偏りに左右されないことを要求する背景の1つとして, 医療診断が挙げられる. 健康な人の群と, 健康でない人の群に分類する場合に, どうしても健康でない人の群は少なくなる. このとき, 医療診断の精度を正しく評価する上でAUCが使われている.

# モデルの精度評価(AUC)⑦

## ➤ AUCの比較3

誤分類率とAUCの値を, 予測データ1と予測データ2ごとにまとめる.

表12: 精度評価比較(予測データ1)

予測データ1		モデル	
		体重モデル	全て猫と分類するモデル
指標	誤分類率	0.3	0.5
	AUC	0.88	0.5

表13: 精度評価比較(予測データ2)

予測データ2		モデル	
		体重モデル	全て猫と分類するモデル
指標	誤分類率	0.2	0.01
	AUC	0.88	0.5

表12, 表13を比べると, AUCは安定して精度評価を行っていることが分かる. したがって, 2群分類モデルの精度評価はAUCが有用である.

データの偏りに左右されないことを要求する背景の1つとして, 医療診断が挙げられる. 健康な人の群と, 健康でない人の群に分類する場合に, どうしても健康でない人の群は少なくなる. このとき, 医療診断の精度を正しく評価する上でAUCが使われている.

# モデルの精度評価(AUC)⑧

- AUCの性質(引用: はじめてのパターン認識, 章末問題3.3)
  - AUCの値がランダム分類の0.5を下回った, AUCの値を上げるにはどうすれば良いか?
  - 現在の結果と逆の分類にすれば良い(犬→猫, 猫→犬). 2群分類において, 全てを不正解にするには, 全てを当てないといけないからである.
- AUCの計算
  - Python, RともにいくつかAUCを計算するパッケージがある.
  - ✓ 第2回のサンプルプログラム内で計算する

～補足資料～

# 補足資料(混同行列)①

- 混同行列(引用: はじめてのパターン認識, 第3章)
- 2群分類では, 対象 $x$ が1つの群に属しているか否かを考えれば良く, 属していると予測する集合を $p$ (陽性:positive), 属していないと予測する集合を $n$ (陰性:negative)とする.

表14: 混同行列(Confusion Matrix)

		予測の分類		合計
		$p$	$n$	
真の 分類	$p^*$	True Positive (TP)	False Negative (FN)	$P = TP + FN$
	$n^*$	False Positive (FP)	True Negative (TN)	$N = FP + TN$

# 補足資料(混同行列)②

## ➤ 記号の整理と評価値(引用: はじめてのパターン認識, 第3章)

表15: 記号の定義1

記号	定義
$p^*$	実際は群に属している集合.
$n^*$	実際は群に属していない集合.
P	$p^*$ の件数.
N	$n^*$ の件数.

表16: 記号の定義2

記号	定義
TP	$p^*$ を $p^*$ と予測した件数.
FN	$p^*$ を $n^*$ と予測した件数.
TN	$n^*$ を $n^*$ と予測した件数.
FP	$n^*$ を $p^*$ と予測した件数.


表17: 良く使用される評価値

名前	意味	定義
偽陽性率	$n^*$ の中で $p^*$ と誤予測した割合.	FP/N
真陽性率	$p^*$ の中で正しく $p^*$ と予測した割合.	TP/P
適合率(Pr)	$p^*$ と予測した中で実際に $p^*$ である割合.	TP/(TP+FP)
再現率(R)	予測対象外も含めた $p^*(=:p_{all}^*)$ のうち, $p^*$ と予測できた割合.	TP/ $P_{all}$
正確度	正しく予測できた割合.	(TP+TN)/(P+N)
F値(F尺度)	適合率と再現率の調和平均(詳しくは補足資料1).	2/(1/Pr+1/R)

# 補足資料(適合率と再現率, ROC曲線)

## ➤ 適合率と再現率の関係

適合率と再現率は二律背反の関係(トレードオフ)であることが分かる。



$$\text{適合率} := TP / (TP + FP)$$

$$\text{再現率} := TP / p_{all}^*$$

$p_{all}^*$ の件数は定数なので、再現率を上げるため、TPを増やそうと $p$ を大きくするとFPも増える可能性があり、結果的に適合率は下がる。

## ➤ ROC曲線の作成

例えば、Model1が2群( $p^*$ :契約,  $n^*$ :非契約)に対して $p^*$ に属する確率を出すとする。このとき、 $X$ を予測するデータ集合とすると、 $x \in X$ に対して、

$$\text{Model1}(x) = y_1 \quad (y_1: \text{スコア})$$

とかける。いま、契約スコアの降順でデータを並べ、上のデータから順に閾値を超える様に、閾値を下げていく、各閾値ごとに閾値を超えるデータを $p^*$ (契約)として偽陽性率と真陽性率を計算し、横軸を偽陽性率、縦軸を真陽性率として、グラフにしたものがROC曲線である。



# 補足資料(MAE)

## ➤ MAE (Mean Absolute Error)

MAEとは,  $N$  = 予測対象数,  $y_i$  = 実現値,  $\hat{y}_i$  = 予測値として,

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

で定義される. 予測対象全てを誤差無しに当てることができれば, スコアは0となり, モデルの誤差の平均を推し量れる.

# 補足資料(NDCG)

## ➤ NDCG (Normalized Discounted Cumulated Gain)

NDCGとは, 何かワードをWEB検索する例を考えると,  $k$  = 表示する検索結果数,  $rel_i$  = 表示 $i$ 番目のWEBページ満足度として,

$$NDCG_k = \frac{DCG_k}{IDCG_k}, \quad DCG_k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i+1)},$$

$IDCG_k = DCG_k$  最大スコア(満足度の高い順に検索結果を表示)

で定義される. 満足度の高い順に検索結果を表示できれば, 最大スコアの1となり, 0に近づくほど精度が悪くなる.

### ✓ 具体例

表2: 検索結果表示順序と満足度

WEBページ	$i$ : 表示順序	$rel_i$ : 満足度
A	1	5
B	3	4
C	2	3

$$DCG_k = \frac{2^5 - 1}{\log_2(1+1)} + \frac{2^4 - 1}{\log_2(3+1)} + \frac{2^3 - 1}{\log_2(2+1)} \doteq 42.916$$

$$IDCG_k = \frac{2^5 - 1}{\log_2(1+1)} + \frac{2^4 - 1}{\log_2(2+1)} + \frac{2^3 - 1}{\log_2(3+1)} \doteq 43.964$$

$$NDCG_k = \frac{DCG_k}{IDCG_k} \doteq 0.976$$

# 補足資料(MAP@n)

## ➤ MAP@n (Mean Average Precision)

MAP@nとは, 最大 $n$ 個の商品推薦の例を考えると,  
 $U$  = 予測対象人数,  $p_u(k)$  = ユーザ $u$ において $k$ 番目までの当たり確率,  
 $h$  = 予測した商品数,  $m$  = ユーザ $u$ が実際に購入した商品数として,

$$\text{MAP@n} = \frac{1}{U} \sum_{u=1}^U \left( \frac{1}{\min(m, n)} \sum_{k=1}^{\min(h, n)} P_u(k) \right)$$

$m=0$ のとき,

$$\frac{1}{\min(m, n)} \sum_{k=1}^{\min(h, n)} P_u(k) = 0$$

で定義される. 最大スコアは  $\sum_{k=1}^n 1/k$  (標準化された場合は1).

# 補足資料(Log Loss)

## ➤ Log Loss

Log Lossとは, 3群以上の分類に用いられることが多く,  $N$  = 予測対象数,  $M$  = 分類する群数,  $y_{ij}$  =  $i$ 番目の対象が真に $j$ 番目の群のとき1, そうでないとき0,  $p_{ij}$  =  $i$ 番目の対象が $j$ 番目の群である予測確率として,

$$\text{LogLoss} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^M y_{ij} \log(p_{ij})$$

で定義される. 0に近いほど良いスコアである.

# 引用, 参考文献

- [1] 平井有三：はじめてのパターン認識, 2012年, 森北出版株式会社
- [2] 石田基広：Rで学ぶデータ・プログラミング入門, 2012年, 共立出版